

Rapport Sémantique distributionnelle

Lien repo github : <https://github.com/salmachatoui-a/polybert->

1. Introduction

Ce projet explore la notion de polysémie à travers les embeddings contextuels produits par BERT, modèle de langue développé par Google en 2018. Contrairement aux embeddings statiques comme Word2Vec (vu dans un projet précédent), BERT génère pour chaque occurrence d'un mot un vecteur différent selon son contexte phrastique, ce qui le rend particulièrement adapté à l'étude de la polysémie.

Dans quelle mesure un score de polysémie basé sur ces embeddings contextuels correspond-il à la notion linguistique de polysémie ?

Pour répondre à cette question, nous procédons en six étapes. Nous constituons d'abord un corpus de phrases extraites de Wikipedia pour vingt mots français choisis pour leurs propriétés polysémiques ou monosémiques. Nous extrayons ensuite les embeddings contextuels avec CamemBERT pour chaque occurrence de ces mots. Nous calculons alors un score de polysémie basé sur l'écart-type des similarités cosinus entre embeddings d'un même mot. Nous visualisons ces embeddings en deux dimensions par réduction de dimensionnalité (t-SNE et PCA) afin de confirmer les intuitions. Enfin, nous corrélons notre score avec le nombre de sens définis dans WordNet via la corrélation de Spearman pour valider notre mesure. A cela nous étendons notre analyse aux 671 mots les plus fréquents des 1000 synsets les plus fréquents de WordNet pour confirmer statistiquement notre hypothèse.

2. Méthodologie

Ce projet se décompose de la façon suivante:

2.1 Choix des mots

J'ai choisi 20 mots de façon raisonnée, selon des critères de polysémie et de monosémie pertinents dans le cadre de ce projet.

Les mots choisis sont les suivants;

mots_polysemique = ["café", "souris", "langue", "fraise", "avocat", "bois", "livre", "vol", "action", "tour"]

mots_monosemique = ["médecin", "volcan", "pentathlon", "atome", "photosynthèse", "chrysanthème", "hydrogène", "électron", "antibiotique", "alambic"]

2.2 Constitution du corpus

Les phrases du corpus ont été extraites automatiquement de Wikipédia en français via la bibliothèque wikipediaapi. Pour chaque mot, plusieurs articles thématiques ont été ciblés afin de maximiser la

diversité sémantique des occurrences. Par exemple, pour le mot avocat, les articles « Avocat (fruit) » et « Avocat (métier) » ont été consultés simultanément, garantissant ainsi la présence des deux grands sens du mot.

Une fonction de filtrage retient uniquement les phrases contenant le mot cible (via une expression régulière avec frontière de mot `\b`), dont la longueur est comprise entre 20 et 300 caractères — éliminant les phrases trop courtes (peu informatives) et trop longues (risquant de dépasser la fenêtre de BERT). Un dédoublonnage est effectué avant tout traitement.

2.3 Extraction des embeddings contextuels

Le modèle utilisé est CamemBERT-base, un modèle de type BERT pré-entraîné sur un large corpus français (OSCAR). Il produit pour chaque token un vecteur de 768 dimensions à partir de la dernière couche cachée (`last_hidden_state`).

L'extraction du vecteur d'un mot cible pose un défi propre aux modèles de sous-tokenisation: CamemBERT peut découper un mot comme « fraise » en plusieurs sous-tokens (par exemple « `_fra` » + « `ise` »). La fonction `get_word_embedding` reconstruit le mot en concaténant les sous-tokens successifs, puis calcule la moyenne de leurs vecteurs pour obtenir un embedding unique représentatif de l'occurrence du mot dans son contexte phrastique.

2.4 Calcul du score de polysémie

Le score de polysémie est défini comme l'écart-type des similarités cosinus calculées entre toutes les paires d'embeddings d'un même mot. Pour un mot m disposant de n occurrences, le score est :

$$\text{score}(m) = \sigma(\{1 - \cos(v_i, v_j) \mid i < j\})$$

Où `cos` désigne la distance cosinus au sens de `scipy`, de sorte que $1 - \cos(v_i, v_j)$ correspond à la similarité cosinus classique. Des vecteurs identiques ont une similarité de 1, des vecteurs orthogonaux une similarité de 0.

Un écart-type élevé signifie que les similarités entre paires varient beaucoup : certaines occurrences du mot sont très proches (même sens activé) tandis que d'autres sont très éloignées (sens distincts activés), ce qui traduit une polysémie capturée par le modèle. À l'inverse, un faible écart-type traduit une grande cohérence contextuelle, caractéristique des mots monosémiques. Le nombre d'occurrences est plafonné à 50 par mot pour limiter l'explosion combinatoire du nombre de paires, qui croît selon $C(n,2) = n(n-1)/2$.

2.5 Visualisation par réduction de dimensionnalité

Deux approches de visualisation ont été mises en œuvre. D'une part, une analyse en composantes principales (PCA) par mot, permettant d'observer la structure locale des embeddings d'un seul mot. D'autre part, une projection t-SNE globale sur l'ensemble des vecteurs de tous les mots, permettant de comparer visuellement la dispersion relative des mots polysémiques et monosémiques.

2.6 Corrélation avec WordNet

Afin de valider le score de similarité par rapport à une ressource linguistique externe, le nombre de synsets de chaque mot a été extrait de WordNet français via la bibliothèque NLTK (Open Multilingual WordNet, lang='fra'). Ce nombre constitue un proxy du nombre de sens lexicaux reconnus. La corrélation entre le score de polysémie et ce nombre de sens est mesurée par le coefficient de Spearman.

2.7 Difficultés rencontrées et solutions

a) Alignement token–mot avec CamemBERT

CamemBERT utilise une tokenisation SentencePiece qui peut découper les mots en sous-unités. Il a fallu implémenter une logique de reconstruction des mots à partir des sous-tokens en suivant les marqueurs de début de mot (`_`). Cette reconstruction permet de retrouver fidèlement les indices des tokens correspondant au mot cible, même pour des mots composés ou accentués.

b) Diversité sémantique du corpus

Pour les mots polysémiques, un corpus extrait d'un seul article Wikipédia aurait pu être biaisé vers un seul sens dominant (par exemple, « livre » renvoyant quasi uniquement au sens de « document »). La solution retenue a été de cibler explicitement plusieurs articles thématiques par sens attendu — par exemple « Livre (unité de masse) » et « Livre sterling » en plus de « Livre (document) » — garantissant une couverture multi-sémantique.


c) Mots monosémiques à fort score de polysémie

Certains mots a priori monosémiques comme hydrogène ou volcan présentent des scores de polysémie élevés. Une explication probable est que leurs contextes d'usage sur Wikipédia sont très variés (contextes historiques, chimiques, géologiques, vulgarisation...) ce qui produit une variabilité contextuelle sans pour autant correspondre à de la polysémie au sens lexical.

Ce phénomène illustre une limite du score basé sur la variance contextuelle.

3. Résultats et discussions

Le graphique ci-dessous présente le score de polysémie calculé pour chacun des vingt mots, trié par ordre croissant. La ligne verticale en pointillés représente la moyenne générale.



On observe que les mots polysémiques (rouge) tendent à se concentrer dans la partie supérieure du classement. Les cinq mots avec les scores les plus élevés sont livre (0.160), bois (0.153), avocat (0.150), tour (0.149) et action (0.135), tous polysémiques.


À l'extrémité inférieure, on trouve antibiotique (0.039), alambic (0.042), photosynthèse (0.044) et électron (0.056), tous monosémiques, ce résultat est cohérent.

Cependant, plusieurs cas s'écartent de cette tendance par exemple, hydrogène et volcan, pourtant monosémiques, affichent des scores relativement élevés (0.150 et 0.141), au même niveau que certains mots polysémiques. À l'inverse, fraise (0.077) obtient un score modeste malgré ses trois sens distincts (fruit, outil dentaire, collerette).

Tableau récapitulatif:

mot	score_bert	nb_sens_wordnet	type
livre	0.159374	19	polysémique
bois	0.152607	13	polysémique
avocat	0.150639	8	polysémique
hydrogène	0.150541	1	monosémique
tour	0.148089	18	polysémique
volcan	0.141316	2	monosémique
souris	0.140290	5	polysémique
action	0.134978	17	polysémique
langue	0.121074	14	polysémique
médecin	0.114098	7	monosémique
atome	0.107675	2	monosémique
vol	0.107268	2	polysémique
café	0.101553	6	polysémique
pentathlon	0.091545	1	monosémique
fraise	0.077317	6	polysémique
chrysanthème	0.061539	2	monosémique
électron	0.055990	1	monosémique
photosynthèse	0.043033	1	monosémique
alambic	0.042469	1	monosémique
antibiotique	0.038631	2	monosémique

La projection t-SNE de l'ensemble des embeddings (tous mots confondus) offre une vue globale de la structure de l'espace vectoriel appris par CamemBERT.




Plusieurs observations ressortent clairement. Les mots monosémiques (triangles) forment des nuages très compacts et bien délimités : antibiotique, alambic, photosynthèse, atome, électron, hydrogène et pentathlon occupent chacun une région très concentrée de l'espace, confirmant la cohérence contextuelle de leurs embeddings.

En revanche, les mots polysémiques (cercles) présentent des nuages plus étalés ou multilobés. Le mot livre forme un nuage dispersé dans la région inférieure-droite, reflétant sa forte polysémie (unité monétaire, objet de lecture). langue forme une grappe dense mais isolée en bas du graphique, ce qui suggère que ses occurrences sont contextuellement cohérentes malgré deux sens très différents (organe et système de communication) — peut-être parce que les articles Wikipédia associés utilisent chaque sens de manière cohérente dans des articles distincts.

Les projections PCA individuelles, disponibles en annexe, corroborent les observations issues du t-SNE : les mots monosémiques forment des nuages compacts et concentrés, tandis que les mots polysémiques présentent des distributions plus étendues, avec parfois plusieurs sous-clusters distincts correspondant à leurs différents sens.

La figure ci-dessous présente la corrélation entre le score de polysémie et le nombre de synsets dans WordNet français.



La corrélation de Spearman est $\rho = 0.629$ avec $p = 0.0029$, ce qui constitue une corrélation modérée à forte, statistiquement significative au seuil de 1 %. Ce résultat semble valider l'hypothèse centrale du projet : le score d'écart-type des similarités cosinus capte bien une dimension de la polysémie lexicale. On remarque que les mots polysémiques (orange) se regroupent dans la partie supérieure-droite du graphique (fort score de polysémie, nombreux sens WordNet), tandis que les mots monosémiques (vert) se concentrent en bas à gauche. La droite de régression (tirets) confirme la tendance linéaire croissante.

Deux groupes méritent attention. D'une part, hydrogène et volcan (verts) présentent des scores de polysémie élevés malgré un seul sens WordNet — leur variabilité contextuelle sur Wikipédia dépasse donc leur polysémie lexicale réelle.

D'autre part, fraise (orange) est sous-score par polysémie alors qu'elle possède 6 synsets WordNet, probablement parce que le corpus extrait de Wikipédia ne couvre pas équitablement tous ses sens.

4. Validation statistique à grande échelle

Nous avons vu précédemment que notre intuition sur la corrélation entre les résultats qu'ont produit le score de similarité cosinus et la notion linguistique de polysémie ont semblé être juste. Pour consolider ces résultats nous allons étendre notre analyse à une plus grande échelle de mots, et pour ce faire nous avons choisi les 1000 synsets les plus fréquents issu de Wordnet. Nous avons effectué un nettoyage car pour éviter les mots grammaticaux nous avons pris uniquement les mots de taille supérieure ou égale à 5 lettres. Résultat, nous avons 671 mots, ces mots ont été soumis à CamemBERT pour l'extraction de leurs embeddings contextuels, et nous avons calculé leur écart-type par pair de similarité cosinus.

Cette analyse est computationnellement coûteuse : le temps de traitement croît proportionnellement au nombre de mots et au nombre de phrases extraites par mot, ce qui constitue une contrainte importante à grande échelle.

Salma CHATOUI
21901307

Autre différence, nous ne traitons pas des articles sélectionnés manuellement mais tous les articles Wikipedia correspondant au mot cible.

Nous avons comme résultat la moyenne des mots monosémiques = 0.14 et la moyenne des mots polysémiques = 0.15. Ces résultats ne sont pas significatifs pour en tirer une vraie conclusion.

```
: df_scores.groupby('type')['score_polysemie'].mean()

: type
  False    0.147372
   True    0.153257
  Name: score_polysemie, dtype: float32
```

5. Conclusion

Ce projet a démontré qu'un score de polysémie basé sur l'écart-type des similarités cosinus entre embeddings contextuels de CamemBERT constitue une mesure pertinente et opératoire de la polysémie lexicale en français. La corrélation de Spearman obtenue ($\rho = 0.629$, $p = 0.0029$) avec le nombre de synsets WordNet confirme que ce score capture bien une partie de la structure sémantique que les ressources lexicales traditionnelles encodent.

Les visualisations t-SNE corroborent ces résultats : les mots polysémiques tendent à occuper des régions plus dispersées de l'espace vectoriel, tandis que les mots monosémiques forment des nuages compacts et isolés.

Plusieurs limites ont cependant été identifiées. La qualité et la diversité du corpus Wikipédia influencent fortement le score : certains mots monosémiques apparaissent dans des contextes très variés, ce qui gonfle artificiellement leur score. À l'inverse, des mots polysémiques dont un sens domine largement sur Wikipédia peuvent être sous-évalués. Par ailleurs, la couverture inégale du WordNet français introduit un bruit dans la corrélation de référence. Par ailleurs, l'extension de l'analyse à 671 mots montre que la différence de score moyen entre mots polysémiques (0.153) et monosémiques (0.147) reste très faible à grande échelle, sans qu'aucun test statistique ne permette de la confirmer comme significative.

Des pistes d'amélioration incluent l'enrichissement du corpus avec des sources variées (presse, littérature, forums), l'utilisation de couches intermédiaires de BERT plutôt que de la seule dernière couche.

Une extension au corpus anglais ou en arabe avec BERT permettrait également de comparer le comportement des modèles et d'évaluer la robustesse de la démarche à travers différentes langues.

Références

Pour réaliser je me suis aidé d'un outil d'intelligence artificielle générative, celui-ci m'a aidé à structurer le plan et la méthode pour réaliser ce projet:

Salma CHATOUI
21901307

Étape	Contenu	Outil
1. Choix des mots	10-15 noms/verbes français (polysémiques vs monosémiques)	Manuel
2. Corpus	Extraire des phrases depuis Wikipédia FR	wikipedia Python
3. Embeddings	BERT français (camembert-base)	transformers
4. Score polysémie	Écart-type des similarités cosinus	sklearn
5. Viz 2D	UMAP / t-SNE des embeddings	umap-learn
6. Référence	Nombre de sens dans WOLF / WordNet	nltk + WOLF
7. Corrélation	Spearman entre score BERT et nb de sens	scipy
8. Comparaison EN	Même pipeline avec BERT anglais + WordNet EN	idem

Garí Soler, A. & Apidianaki, M. (2021). Let's Play Mono-Poly: BERT Can Reveal Words' Polysemy Level and Partitionability into Senses. *Transactions of the Association for Computational Linguistics*, 9, 825–844.

Barque, L. & Chaumartin, F.-R. (2007). La polysémie régulière dans WordNet. *Actes de TALN 2007*, Toulouse, France.